Rencana Penggabungan Dataset

Smart Inventory & Cash Flow Copilot — sumber data per modul untuk MVP

Tidak ada satu dataset publik yang memuat seluruh kebutuhan MVP: transaksi multi-cabang, stok, supplier dan lead time, sekaligus data keranjang belanja. Karena itu dataset digabung **per peran**. Setiap dataset menghidupkan satu modul, lalu semua hasilnya bertemu di satu dashboard. Dataset **tidak** digabung baris demi baris, karena berasal dari perusahaan, negara, periode, dan mata uang yang berbeda.

1. Paket Dataset

Minimal
Cukup untuk demo

Dataset
Bibitor (Inventory Analysis Case Study)
Instacart Market Basket Analysis

Yang dibuka
- Vs, reorder point, lead time per vendor
- Hold Reorder dengan cek substitusi
- Capital Reallocation dalam Rupiah
- Alur demo SKU A vs SKU B

Kuat
Minimal + 2 dataset

Dataset
+ Can You Predict Product Backorders?
+ Online Retail II UCI

Yang dibuka
- Predictive Stockout Alert berbasis model
- Dasar Confidence Score
- Uji guardrail Runaway PO: filter >3σ, circuit breaker

Maksimal
Kuat + 2 dataset

Dataset
+ Montgomery County (3 tabel)
+ M5 Forecasting (Walmart)

Yang dibuka
- Validasi pada data riil ritel + grosir
- Angka akurasi forecast untuk Bagian 6 proposal

2. Peta Modul, Dataset, dan Output

Modul di proposal	Dataset	Hasil yang masuk ke dashboard	Paket
Velocity, reorder point, arus kas, Capital Reallocation	**Bibitor**	Vs per SKU per cabang, lead time per vendor, rekomendasi pengalihan modal dalam Rupiah	Minimal
Logika substitusi (Market Basket)	**Instacart**	Aturan “kategori X sering dibeli bersama Y”	Minimal
Predictive Stockout Alert	**Product Backorders**	Model risiko stok habis	Kuat
Guardrail Runaway PO	**Online Retail II**	Skenario uji pesanan borongan untuk filter >3σ	Kuat
Validasi data riil ritel + grosir	**Montgomery County**	Vs dan pola slow/fast-moving pada data riil	Maksimal
Klaim akurasi forecast	**M5**	Angka akurasi untuk Bagian 6 proposal	Maksimal

3. Detail Dataset dan Link

Inventory Analysis Case Study (Bibitor LLC) — Minimal

Link	https://www.kaggle.com/datasets/bhanupratapbiswas/inventory-analysis-case-study
Isi	6 file CSV: stok awal, stok akhir, pembelian per PO, invoice supplier, penjualan, dan daftar harga beli/jual. Jaringan toko wine & spirits fiktif dengan sekitar 80 cabang, periode 12 bulan (2016). Tabel pembelian memuat supplier, nomor PO, tanggal PO, tanggal terima, tanggal bayar, harga beli, kuantitas, dan klasifikasi produk.
Dipakai untuk	**Vs = $\Sigma S_t \div (n \times I_{avg})$** per SKU per cabang, dengan I_{avg} = rata-rata stok harian hasil rekonstruksi. Lead time per vendor = tanggal terima − tanggal PO. Reorder point dan safety stock. Waktu kas keluar dari tanggal bayar. Margin dari harga jual vs harga beli untuk Capital Reallocation. Selisih stok rekonstruksi vs stok akhir tercatat menjadi dasar Data Confidence Score.

Inventory Analysis Case Study (Bibitor LLC) — Minimal

Catatan	Lisensi di Kaggle tertulis Apache 2.0, tetapi materi aslinya milik HUB of Analytics Education untuk keperluan pendidikan: aman untuk hackathon non-komersial dengan atribusi, jangan untuk pilot komersial. Unduhan ±65 MB terkompresi; setelah diekstrak file pembelian ±400 MB dan penjualan ±128 MB (olah dengan DuckDB atau Kaggle Notebook). Stok hanya snapshot awal dan akhir, jadi stok harian direkonstruksi: stok awal + pembelian − penjualan. Tidak ada ID keranjang. Deskripsi di Kaggle menyebut perusahaan manufaktur; abaikan, isinya data Bibitor.

Instacart Market Basket Analysis — Minimal

Link	https://www.kaggle.com/competitions/instacart-market-basket-analysis
Isi	±3,4 juta order dari 206.209 pengguna, 49.685 produk, 21 departemen, dan 134 aisle (termasuk aisle alkohol seperti red wine dan white wine).
Dipakai untuk	Aturan asosiasi (support, confidence, lift) di level aisle untuk menentukan apakah suatu kategori punya peran komplementer. Hasilnya dipetakan ke kategori Bibitor (lihat Bagian 4B) untuk keputusan Hold Reorder.
Catatan	Data kompetisi: harus menerima aturan kompetisi di Kaggle sebelum mengunduh. Tidak ada data toko, stok, maupun harga.

Can You Predict Product Backorders? — Kuat

Link	https://www.kaggle.com/c/untadta
Isi	23 kolom per SKU: stok saat ini, lead time, barang dalam perjalanan, forecast 3/6/9 bulan, penjualan 1/3/6/9 bulan, stok minimum, performa supplier 6 dan 12 bulan, barang telat dari supplier, flag risiko, dan target *went_on_backorder*. File training ±1,69 juta baris.
Dipakai untuk	Melatih classifier risiko stok habis. Fitur yang sama dihitung ulang dari Bibitor (Bagian 4C), lalu model menilai setiap SKU. Skor risikonya menjadi dasar Confidence Score pada Predictive Stockout Alert.
Catatan	Kelas sangat tidak seimbang: pakai class weight atau undersampling, dan ukur dengan PR-AUC. Domainnya suku cadang, jadi tampilkan sebagai model pra-latih yang dikalibrasi ulang di pilot Fase 2. Lisensi belum terverifikasi.

Online Retail II UCI — Kuat

Link	https://www.kaggle.com/datasets/mashlyn/online-retail-ii-uci
Isi	Seluruh transaksi retailer online di Inggris, 1 Desember 2009 – 9 Desember 2011, per invoice. Banyak pelanggannya pedagang grosir. Lisensi CC0.
Dipakai untuk	Mengambil pola pesanan borongan (kuantitas ekstrem) untuk diinjeksikan ke alur demo, lalu menguji filter outlier >3σ, batas nominal PO harian, dan circuit breaker. Bisa juga menjadi cadangan data Market Basket.
Catatan	Invoice berawalan “C” adalah pembatalan. Hanya satu toko online, tanpa data stok.

Montgomery County Alcohol Beverage Services (3 tabel) — Maksimal

Link	Warehouse and Retail Sales — https://data.montgomerycountymd.gov/d/v76h-r7br Product Purchases by DLC — https://data.montgomerycountymd.gov/d/kpfd-c5d5 ABS Store Inventory and Sale Items — https://data.montgomerycountymd.gov/d/ib5t-5ncy Salinan Kaggle (tabel penjualan saja): https://www.kaggle.com/datasets/divyeshardeshana/warehouse-and-retail-sales
Isi	Data riil lembaga county yang mengoperasikan gudang untuk pelanggan grosir dan 26 toko ritel. Per item per bulan (satuan karton): penjualan ritel gabungan semua toko, transfer gudang ke toko, dan penjualan grosir. Pembelian per item per vendor per bulan. Total stok dan harga per item (harian).

Montgomery County Alcohol Beverage Services (3 tabel)	Maksimal
Dipakai untuk	Memvalidasi perhitungan Vs serta pola slow/fast-moving pada data riil ritel + grosir. Memperkuat argumen “data riil” di depan juri.
Catatan	Bukan dari Kaggle (portal data county / data.gov). Lisensi tidak dicantumkan. Data **tidak dipecah per toko**: penjualan ritel adalah gabungan semua toko dan stok adalah total per item. Tabel stok hanya snapshot saat diunduh, jadi riwayatnya perlu dikumpulkan sendiri selama beberapa hari.

M5 Forecasting – Accuracy (Walmart)	Maksimal
Link	https://www.kaggle.com/competitions/m5-forecasting-accuracy
Isi	Penjualan harian 3.049 produk di 10 toko Walmart (California, Texas, Wisconsin) selama ±1.941 hari, dengan harga per toko per minggu dan kalender event.
Dipakai untuk	Benchmark akurasi forecast: bandingkan model kalian dengan baseline sederhana memakai metrik yang sama, lalu isi kolom “Akurasi Prediksi Permintaan” di Bagian 6. Juga kasus uji Death Spiral, karena penjualan nol di sini bisa berarti stok habis atau memang tidak laku.
Catatan	Tidak ada data stok maupun supplier. Data kompetisi: terima aturan kompetisi sebelum mengunduh.

4. Cara Penggabungan

A. Per modul (cara utama)

Setiap dataset menjalankan modulnya sendiri dan hanya **output**-nya yang bertemu di dashboard: Vs dan lead time dari Bibitor, aturan asosiasi dari Instacart, skor risiko dari model Backorders, skenario uji dari Online Retail II. Tidak ada join antar-tabel di level baris.

B. Jembatan kategori: Bibitor ↔ Instacart

Bibitor adalah jaringan wine & spirits dan tabel pembeliannya punya kolom klasifikasi produk. Instacart punya aisle alkohol seperti red wine dan white wine. Aturan asosiasi dipelajari di level aisle Instacart, lalu dipetakan ke kategori Bibitor lewat tabel mapping manual (misalnya aisle *red wines* → kategori wine Bibitor). Granularitasnya kategori, bukan merek, tetapi cukup untuk demo “SKU B di-hold karena kategorinya tidak punya peran komplementer”.

C. Transfer model: Product Backorders → Bibitor

Model dilatih di data Backorders. Fitur yang sama dihitung ulang dari Bibitor pada tanggal t, lalu model menilai risiko stok habis untuk setiap SKU per cabang:

Fitur Backorders	Cara menghitung dari Bibitor
national_inv	Stok hasil rekonstruksi pada tanggal t
lead_time	Rata-rata (tanggal terima − tanggal PO) per vendor
in_transit_qty	Jumlah barang dari PO dengan tanggal PO ≤ t < tanggal terima
sales_1/3/6/9_month	Total penjualan pada jendela 1, 3, 6, dan 9 bulan sebelum t
forecast_3/6/9_month	Output model demand forecast kalian
perf_6/12_month_avg	Proksi: konsistensi lead time vendor (misalnya 1 − koefisien variasi)

Data Bibitor hanya 12 bulan, jadi jendela 9 bulan baru tersedia untuk tanggal di akhir periode.

Yang perlu dihindari

- Jangan menggabungkan baris antar-dataset seolah satu perusahaan. Periodenya berbeda (Bibitor 2016, Online Retail II 2009–2011), begitu juga negara dan mata uangnya.
- Konversi USD ke Rupiah dengan satu kurs tetap yang dicantumkan, dan beri label “simulasi”.
- Tambahkan satu slide “Sumber data per modul” di pitch. Transparansi menambah kredibilitas.
- Simpan atribusi dan catatan lisensi setiap dataset.

5. Alur Demo yang Disarankan

Mengikuti skop demo di Bagian 4 proposal (lonjakan SKU A vs stagnasi SKU B), dengan sumber data untuk tiap langkah:

1	**Ingestion** Bibitor · **Minimal**	CSV Bibitor masuk ke Amazon S3, lalu ke RDS atau DuckDB. Stok harian direkonstruksi per SKU per cabang. Selisih dengan stok akhir tercatat menghasilkan Data Confidence Score.
2	**Penalaran** Bibitor · **Minimal**	Hitung Vs dan lead time. Pilih SKU A (Vs naik tajam) dan SKU B (Vs turun, stok tinggi) di cabang yang sama.
3	**SKU A: draf PO** Bibitor + Backorders · **Kuat**	Model risiko memberi skor dan perkiraan tanggal stok habis. Agen menyusun draf PO ke SAP (simulasi API) yang menunggu 1-Click Approval.
4	**SKU B: Hold Reorder** Bibitor + Instacart · **Minimal**	Cek aturan asosiasi kategori. Tidak ada peran komplementer, jadi status menjadi Hold Reorder; exploration budget kuartalan tetap dialokasikan.
5	**Capital Reallocation** Bibitor · **Minimal**	Modal yang ditahan dari SKU B direkomendasikan untuk SKU A, ditampilkan dalam Rupiah.
6	**Uji guardrail** Online Retail II · **Kuat**	Injeksi pesanan borongan. Filter >3σ menahan draf PO dan circuit breaker aktif.
7	**Slide validasi** Montgomery + M5 · **Maksimal**	Vs pada data riil ritel + grosir, dan angka akurasi forecast vs baseline.

6. Daftar Link

Dataset	Paket	Link
Bibitor – Inventory Analysis Case Study	**Minimal**	https://www.kaggle.com/datasets/bhanupratapbiswas/inventory-analysis-case-study
Instacart Market Basket Analysis	**Minimal**	https://www.kaggle.com/competitions/instacart-market-basket-analysis
Can You Predict Product Backorders?	**Kuat**	https://www.kaggle.com/c/untadta
Online Retail II UCI	**Kuat**	https://www.kaggle.com/datasets/mashlyn/online-retail-ii-uci
Montgomery – Warehouse and Retail Sales	**Maksimal**	https://data.montgomerycountymd.gov/d/v76h-r7br
Montgomery – Product Purchases by DLC	**Maksimal**	https://data.montgomerycountymd.gov/d/kpfd-c5d5
Montgomery – ABS Store Inventory and Sale Items	**Maksimal**	https://data.montgomerycountymd.gov/d/ib5t-5ncy
Montgomery – salinan Kaggle (penjualan)	**Maksimal**	https://www.kaggle.com/datasets/divyeshardeshana/warehouse-and-retail-sales
M5 Forecasting – Accuracy	**Maksimal**	https://www.kaggle.com/competitions/m5-forecasting-accuracy

Referensi pendukung

- Tutorial kasus Bibitor: struktur tabel dan rekonstruksi stok (RCourse)
  https://shengpeishu.quarto.pub/rcourse-r4db/Inventory_case.html
- Deskripsi kolom Product Backorders (Papers with Code)
  https://ml.paperswithcode.com/dataset/can-you-predict-product-backorder
- Studi prediksi backorder yang memakai dataset ini (MDPI Sensors, 2021)
  https://www.mdpi.com/1424-8220/21/23/7926
- Profil Montgomery County Alcohol Beverage Services: 26 toko ritel + grosir
  https://www.montgomerycountymd.gov/BONDS/Resources/Files/DLC_Continuing_Disclosure_FY2020.pdf